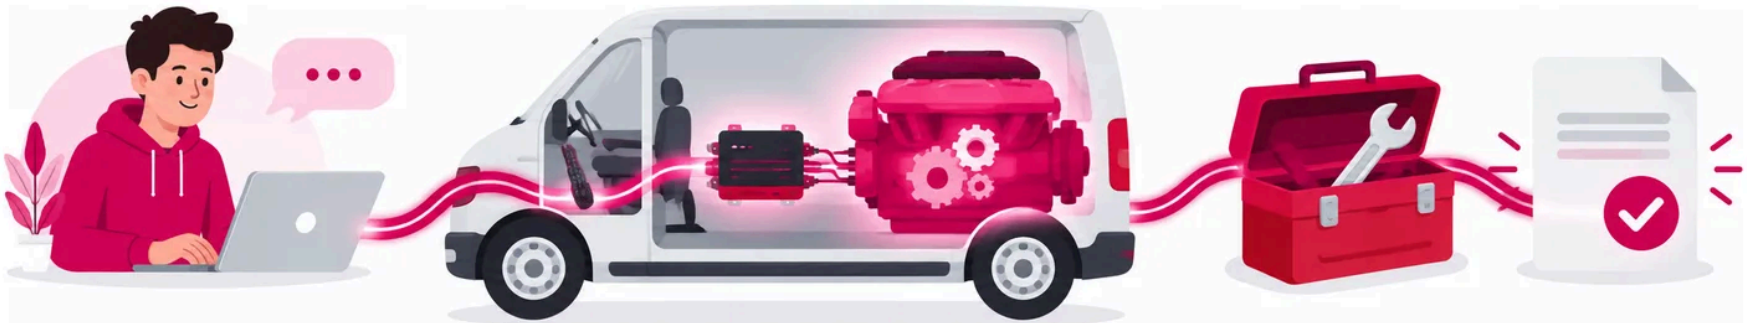
ZENIKA · FORMATION IA · 2H

L’IA sous le capot

Comprendre l’environnement de l’IA, sans jargon

Moteur, véhicule, dispatch, boîtier : une image pour chaque mot qu’on entend en réunion.

À la fin de la session, vous saurez…



Le fil rouge : suivre une demande, de la question posée jusqu'au travail livré.

Situer
qui est qui
PARTIE 1

Comprendre
le moteur
PARTIE 2

Reconnaître
un agent
PARTIE 3

Organiser
une flotte d'agents
PARTIE 4

Questionner
sécurité et coûts
PARTIE 5

© ZENIKA 2026 | All rights reserved

Agenda

1. Ouverture — 5 min
2. La carte : qui est qui — 15 min
3. Le moteur : comment pense un modèle — 40 min
4. Le véhicule : ce qu'est un agent — 20 min
5. La flotte : plusieurs agents — 15 min
6. Le code de la route : sécurité et contrôle — 20 min
7. Synthèse et questions — 5 min

© ZENIKA 2026 | All rights reserved

Partie 1 · 15 min

La carte : qui est qui

Six mots qu’on entend partout, une image pour chacun.



© ZENIKA 2026 | All rights reserved

Une entreprise de livraison

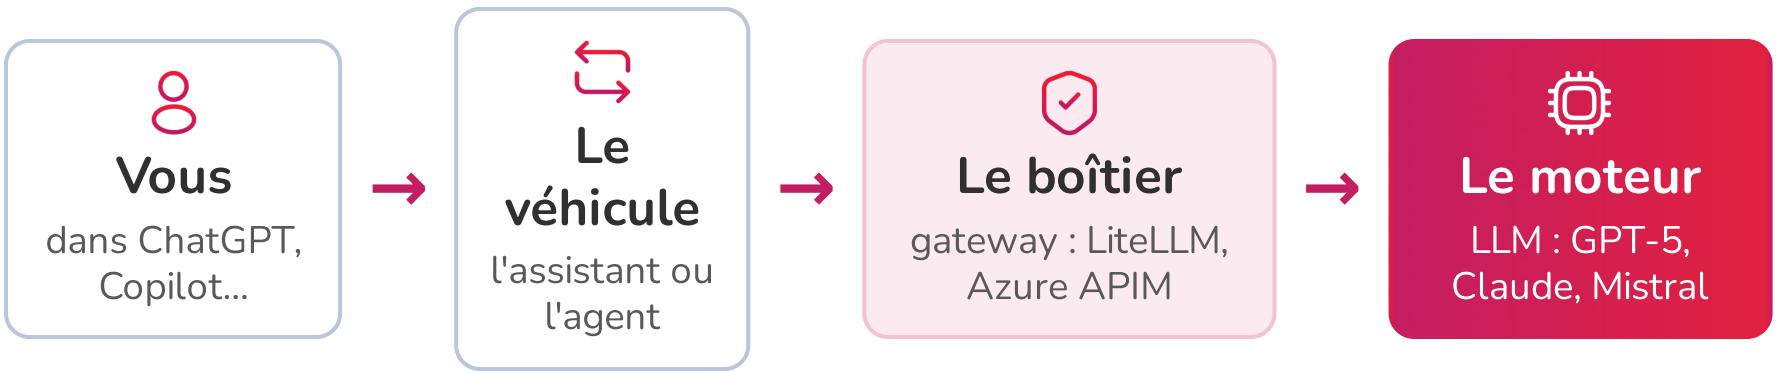
DÉTAIL ↗



LLM	→	le moteur ChatGPT, Claude, Mistral...
SLM	→	le petit moteur Mistral Small, Phi, Gemma : une citadine
Agent	→	le véhicule en mission ChatGPT agent, Copilot agent
Harness	→	son équipement outils, droits, consignes autour du moteur
Orchestrateur	→	le dispatch LangGraph, CrewAI, n8n
SDD	→	le dispatch par bons de commande GitHub Spec Kit, Kiro

© ZENIKA 2026 | All rights reserved

Qui parle à qui



Le moteur propose, le véhicule agit.

© ZENIKA 2026 | All rights reserved

Quiz : qui est qui ?

ChatGPT

assistant : harness + outils

le véhicule à qui vous passez commande

GPT-5, Claude, Mistral Large

LLM

le moteur

Mistral Small sur Ollama

SLM en local

la citadine

Copilot agent

agent

le véhicule

Power Automate + IA

workflow

la ligne de bus

NotebookLM

assistant sur vos sources

il travaille à livre ouvert

MCP

protocole d'outils

le quai de chargement standard

Claude Code

harness + agent

l'équipement

LangGraph

orchestrateur

le dispatch

GitHub Spec Kit

SDD

le dispatch par bons de commande

Llama Guard

guardrail

un contrôle du boîtier

LiteLLM

gateway

le boîtier

© ZENIKA 2026 | All rights reserved

Partie 2 · 40 min

Le moteur : comment pense un modèle

Ce qui se passe sous le capot, et pourquoi l'IA invente, oublie ou coûte cher.

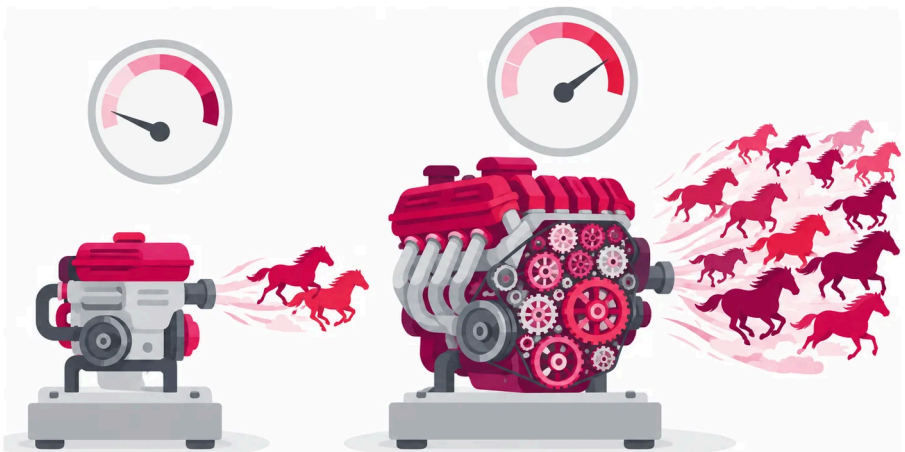


© ZENIKA 2026 | All rights reserved

La puissance du moteur : les chevaux

DÉTAIL ↗

EN VRAI les paramètres · Llama 3.1 : 8, 70 ou 405 milliards · Mistral Small : 24 milliards · GPT-5, Claude : non publié



PARAMÈTRES

Les chevaux d'un modèle, ce sont ses paramètres.

Des milliards de petits réglages, fixés à l'usine. Plus il y en a, plus le moteur est puissant, et gourmand.

Plus de puissance
il raisonne mieux

Plus de consommation
chaque réponse coûte plus

Plus de place
un datacenter, pas un garage

© ZENIKA 2026 | All rights reserved

Citadine ou poids lourd ?

DÉTAIL ↗

EN VRAI SLM : Phi-4, Gemma 3, Mistral Small, via Ollama · LLM : GPT-5, Claude, Gemini



petit modèle · SLM

La citadine

économique, rapide, peut rester au garage : vos données ne sortent pas

grand modèle · LLM

Le poids lourd

puissant, polyvalent, dans le cloud du fournisseur

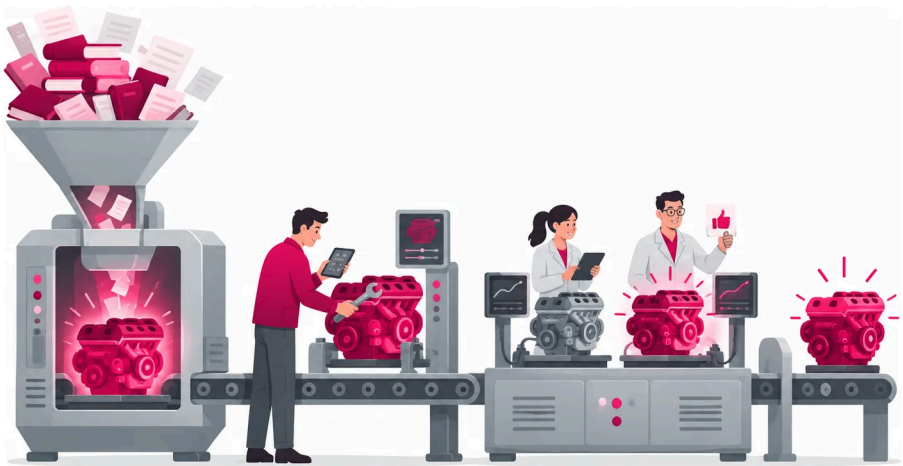
© ZENIKA 2026 | All rights reserved

L’usine à moteurs

DÉTAIL ↗

EN VRAI

pré-entraînement → fine-tuning → RLHF · quelques motoristes : OpenAI, Anthropic, Google, Mistral, Meta



① fabriquer · pré-entraînement

à partir d'une montagne de textes

↓

② régler · fine-tuning

en faire un assistant

↓

③ banc d'essai · RLHF

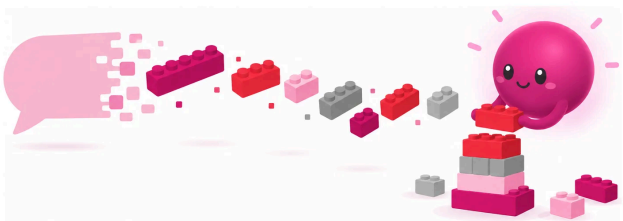
garder les meilleures réponses

© ZENIKA 2026 | All rights reserved

Des briques de Lego, pas des mots

DÉTAIL ↗

EN VRAI les tokens · une page ≈ 600 tokens · les API facturent au million de tokens



Phrase — `Le` `chat` `dort` — 3 mots → 3 tokens

Mot rare — `Anti` `constitution` `nellement` — 1 mot → 3 tokens

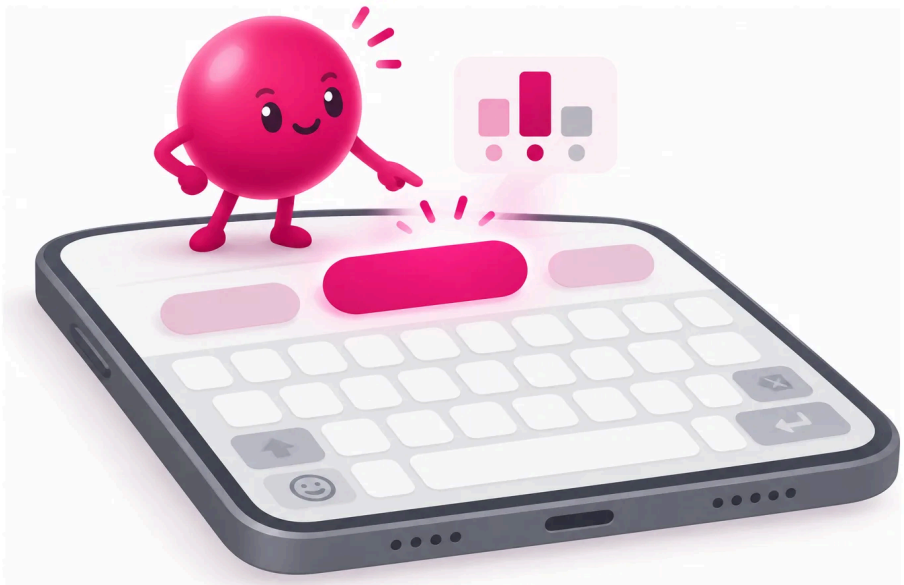
Le modèle lit, écrit et facture en briques : les « tokens ».

© ZENIKA 2026 | All rights reserved

Une autocomplétion géante

DÉTAIL ↗

EN VRAI un LLM (GPT-5, Claude, Gemini, Mistral) prédit le token suivant



Après « Le chat dort sur le »

canapé	41 %
lit	22 %
tapis	9 %
clavier	4 %

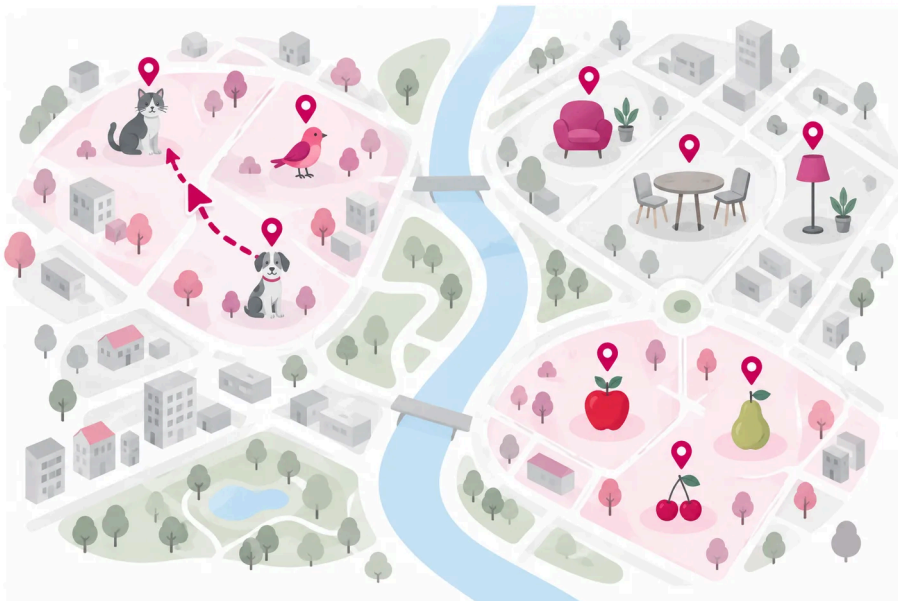
Il choisit une brique, l'ajoute, et recommence.

© ZENIKA 2026 | All rights reserved

Le GPS des sens

DÉTAIL ↗

EN VRAI les embeddings · la base de la recherche sémantique dans vos documents



Chaque mot a une adresse.

Les mots de sens proche habitent le même quartier.

Chercher par le sens

« congés » trouve « vacances »

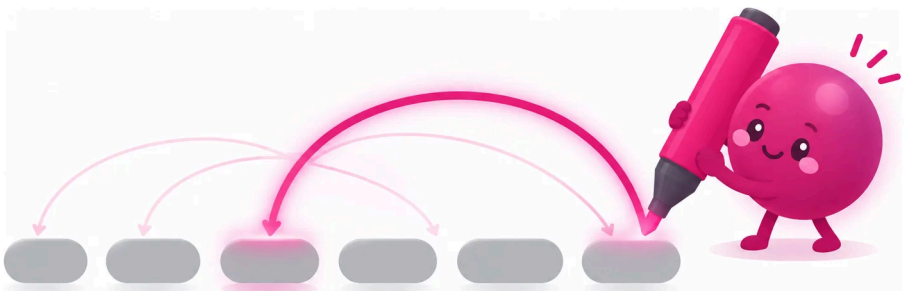
Rapprocher des documents

sans mot commun

© ZENIKA 2026 | All rights reserved

Le surligneur : relier les mots entre eux

EN VRAI le mécanisme d'attention des transformers, le « T » de GPT



Le **chat** ne traverse pas car **il** est fatigué.

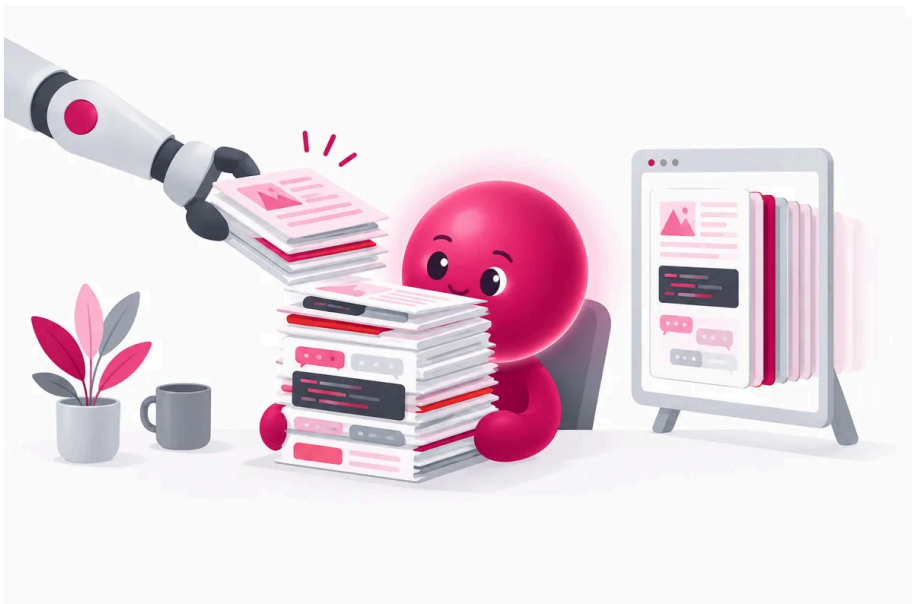
Pour comprendre « il », le modèle surligne « chat ».

© ZENIKA 2026 | All rights reserved

Le plan de travail : sa seule mémoire

DÉTAIL ↗

EN VRAI la context window · de l'ordre de 200 000 à 1 million de tokens selon le modèle



Une taille limitée

quelques centaines de pages au mieux

Tout est relu à chaque message

la conversation entière, depuis le début

Vidé à chaque nouvelle conversation

© ZENIKA 2026 | All rights reserved

Ce qu’il y a sur le plan de travail

DÉTAIL ↗

EN VRAI la context window se mesure en tokens · ici 200 000, environ 330 pages · une page ≈ 600 tokens

À chaque message
tout est renvoyé au moteur



Consignes fixe
les règles de l'outil (le prompt système), vos instructions, la description des outils

Mémoire fixe
les post-it recollés à chaque conversation : ce que l'outil sait de vous

Documents ça grossit
pièces jointes, pages web, résultats de recherche : un PDF de 50 pages ≈ 30 000 tokens

Historique ça grossit
tous vos messages et toutes ses réponses ; chaque échange ajoute 1 000 à 2 000 tokens

Votre message nouveau
la question du moment : souvent le plus petit bloc

Place libre réservée
la réponse s'écrit aussi sur le plan de travail, brique par brique

© ZENIKA 2026 | All rights reserved

Quand le plan de travail déborde

DÉTAIL ↗

EN VRAI la context window pleine · troncature, compaction (résumé automatique), « lost in the middle »

Après deux heures
200 000 tokens atteints



0 token — *barre pas à l'échelle : les petits blocs sont élargis* — 200 000 tokens : la limite

Il oublie le début
les premiers échanges sont coupés ou résumés

Il se perd au milieu
il lit mieux le début et la fin

Plus lent, plus cher
200 000 tokens relus à chaque message

La parade
nouvelle conversation, avec un résumé et les bons documents

© ZENIKA 2026 | All rights reserved

Vrai ou faux ?

« L'IA se souvient de moi d'une fois sur l'autre. »

faux, sauf « mémoire » (ChatGPT, Claude, Copilot)

« L'IA cherche la réponse sur Internet. »

faux, sauf recherche web activée

« Plus le document est long, plus ça coûte. »

vrai : on paie au token

« Ce que je lui apprends, il le retient pour tous. »

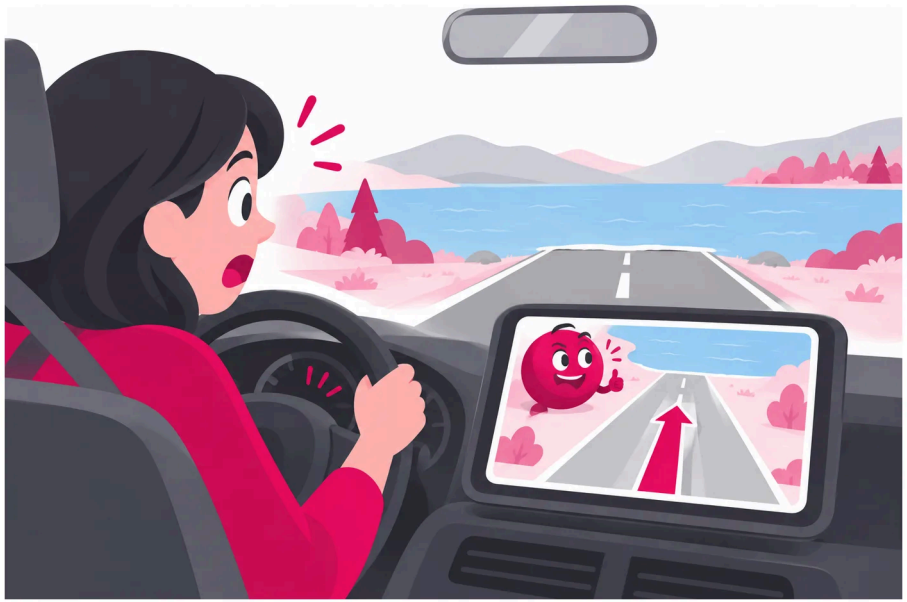
faux : le modèle ne change pas

© ZENIKA 2026 | All rights reserved

Le GPS sûr de lui : l'hallucination

DÉTAIL ↗

EN VRAI hallucination · en 2023, des avocats sanctionnés pour six jurisprudences inventées par ChatGPT



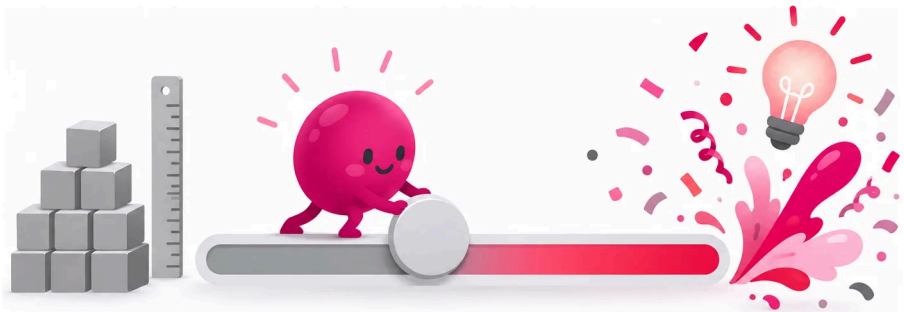
Assuré ne veut pas dire exact.

- Lui donner vos documents
- Demander ses sources
- Vérifier chiffres, noms, dates

© ZENIKA 2026 | All rights reserved

Le curseur de créativité

EN VRAI la **température** · réglable dans les API et les outils d'entreprise (0 = le plus régulier)



curseur bas

Régulier

extraire, résumer, classer

curseur haut

Inventif

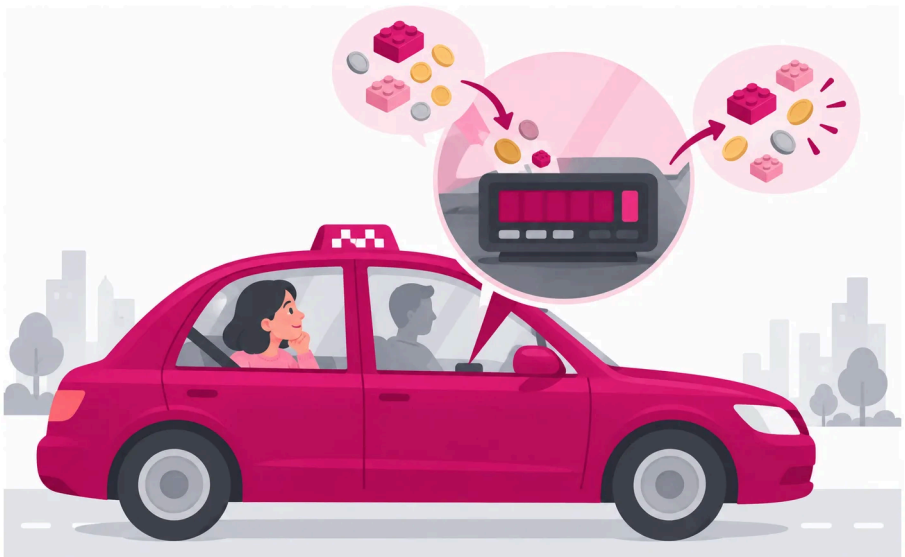
idées, slogans, variantes

© ZENIKA 2026 | All rights reserved

Le taxi au compteur

DÉTAIL ↗

EN VRAI prix par **million de tokens** · **prompt caching** : jusqu'à –90 % sur la partie répétée



On paie ce qu'on envoie

question, documents, historique

Et ce qu'on reçoit

souvent plus cher

Le trajet habituel est moins cher

le cache

© ZENIKA 2026 | All rights reserved

Partie 3 · 20 min

Le véhicule : ce qu’est un agent

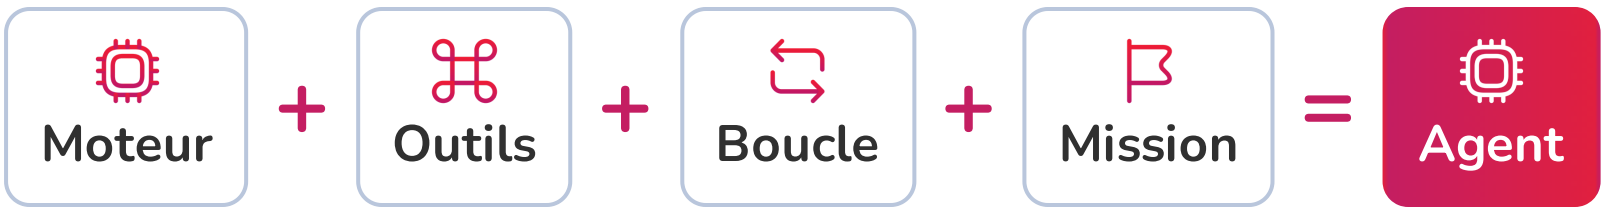
Un moteur, des outils, une boucle et une mission.



© ZENIKA 2026 | All rights reserved

Agent = moteur + outils + boucle + mission

EN VRAI ChatGPT agent, Copilot agent · le modèle écrit un tool call, le logiciel l'exécute



Le moteur demande une action, le véhicule l'exécute ou la refuse.

© ZENIKA 2026 | All rights reserved

La boucle du livreur

DÉTAIL ↗

EN VRAI la boucle d'agent · chaque tour = un appel au modèle + un appel d'outil



① **Regarder**

↓

② **Agir**

↓

③ **Vérifier**

↺

jusqu'à la mission accomplie

© ZENIKA 2026 | All rights reserved

La boîte à outils et le quai de chargement

DÉTAIL ↗

EN VRAI des serveurs MCP existent pour Google Drive, Jira, Slack, Notion, GitHub…



MCP · MODEL CONTEXT PROTOCOL

Le quai de chargement standard des services.

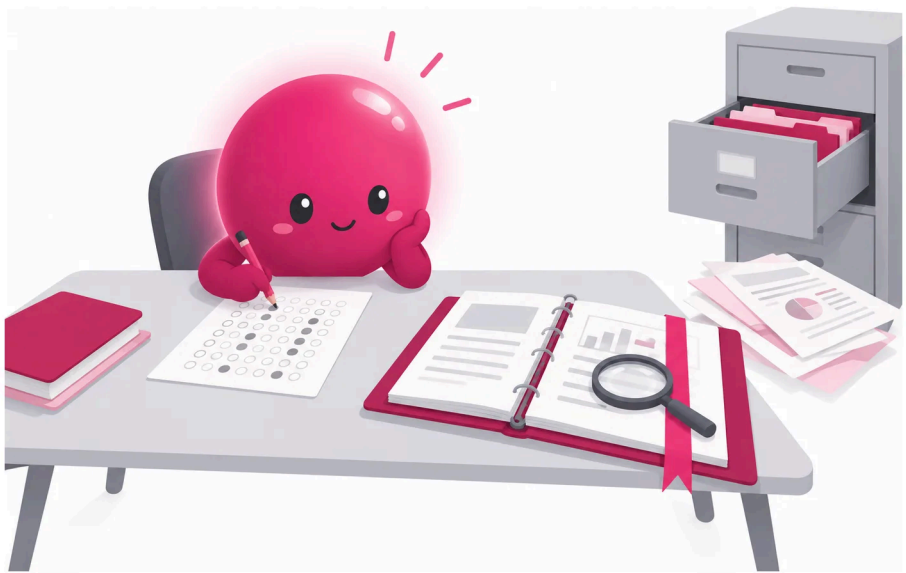
Chaque service ouvre son quai une fois ; tous les agents compatibles peuvent s'y garer.

© ZENIKA 2026 | All rights reserved

L’examen à livre ouvert

DÉTAIL ↗

EN VRAI le RAG · la technique derrière Copilot sur SharePoint et les assistants « sur vos documents »



① **Chercher les bonnes pages** dans vos documents

↓

② **Les poser sur le plan de travail**

↓

③ **Répondre en les citant**

© ZENIKA 2026 | All rights reserved

Post-it, carnet, archives

EN VRAI l'**historique** · la **mémoire** de ChatGPT, Claude, Copilot · une **base documentaire**



Le post-it

la conversation en cours

Le carnet

vos préférences, recollées à chaque fois

Les archives

les documents de l'entreprise

© ZENIKA 2026 | All rights reserved

Les sorties de route

DÉTAIL ↗

EN VRAI boucle infinie · faux succès · coût non borné · injection de prompt



Il tourne en rond

parade : limiter les tours



Il dit « fini » trop tôt

parade : vérifier le résultat



Le compteur s'emballe

parade : un budget par tâche



Il obéit à un faux ordre

parade : partie 5

© ZENIKA 2026 | All rights reserved

Partie 4 · 15 min

La flotte : plusieurs agents

L'équipement, le dispatch et ses bons de commande.



© ZENIKA 2026 | All rights reserved

L’équipement fait le véhicule

DÉTAIL ↗

EN VRAI le harness · ChatGPT, Copilot, Claude Code : des moteurs proches, des équipements différents



HARNESS

Même moteur, véhicules différents.

- Ses outils
- Ses autorisations
- Ses consignes
- Son journal de bord

© ZENIKA 2026 | All rights reserved

Le dispatch

EN VRAI

un orchestrateur · LangGraph, CrewAI, n8n, les sous-agents de Claude Code ou Copilot



ORCHESTRATEUR

Il répartit les tournées entre les véhicules.

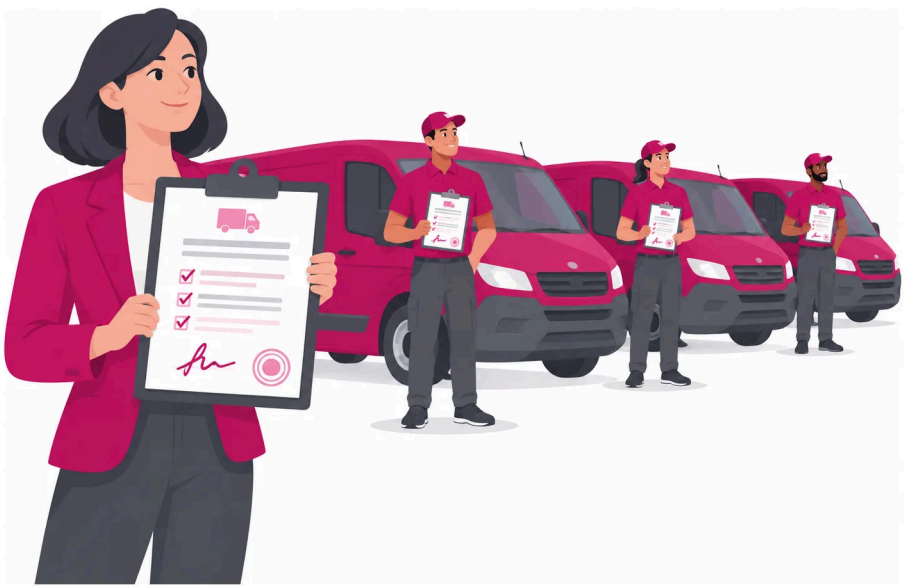
Qui fait quoi, dans quel ordre, et que faire si un véhicule tombe en panne.

© ZENIKA 2026 | All rights reserved

Le dispatch par bons de commande

DÉTAIL ↗

EN VRAI le SDD · GitHub Spec Kit, Kiro : spec → plan → tâches → agents



①

Signer le bon de commande

la spec, relue par un humain

↓

②

Le découper en bons de tournée

le plan, puis les tâches

↓

③

Dispatcher et vérifier

chaque livraison contre son bon

© ZENIKA 2026 | All rights reserved

À vous : de quoi avez-vous besoin ?

Reformuler un mail délicat à un client

un chatbot

ChatGPT, Copilot Chat

Chaque lundi, résumer les tickets de la semaine pour l'équipe

un workflow

n8n, Make, Power Automate

Répondre à un client sur sa commande, en consultant le CRM

un agent

Copilot agent, un agent de support

Préparer une réponse à appel d'offres : juridique, technique, prix

un orchestrateur et plusieurs agents

LangGraph, CrewAI + un bon de commande relu

© ZENIKA 2026 | All rights reserved

Partie 5 · 20 min

Le code de la route : sécurité et contrôle

Des véhicules qui lisent, écrivent et envoient : comment l'entreprise garde le contrôle ?

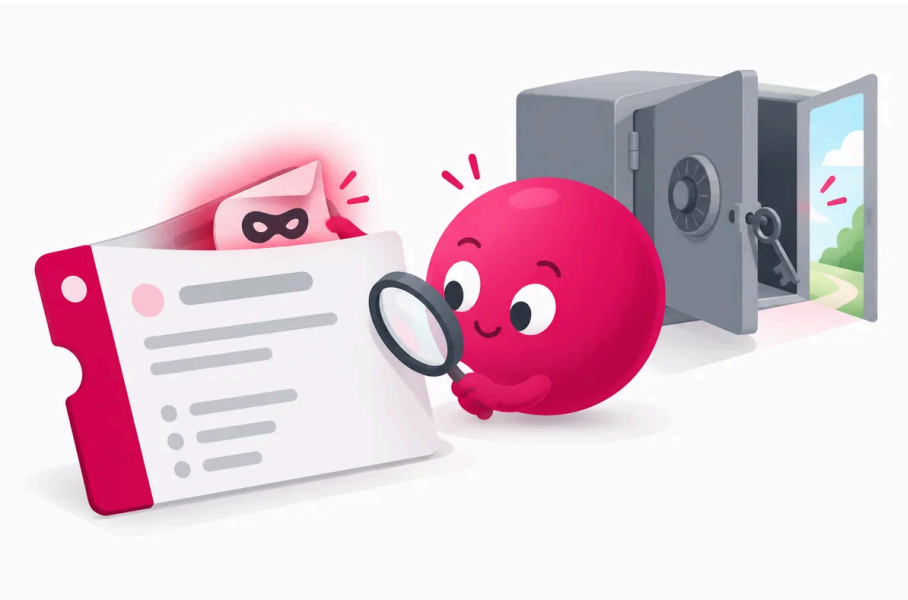


© ZENIKA 2026 | All rights reserved

Le faux ordre de mission

DÉTAIL ↗

EN VRAI un CV avec du texte blanc caché, un mail piégé lu par un assistant · OWASP LLM01



INJECTION DE PROMPT · RISQUE N° 1

Une consigne cachée dans ce que l'agent lit.

Pour le modèle, tout est du texte : il ne distingue pas une donnée d'un ordre.

© ZENIKA 2026 | All rights reserved

Les clés, l’inconnu et la porte ouverte

DÉTAIL ↗

EN VRAI le trio létal (Simon Willison, 2025)



Les clés
accès à vos données

L'inconnu
il lit du contenu non fiable

La porte ouverte
il peut envoyer vers l'extérieur

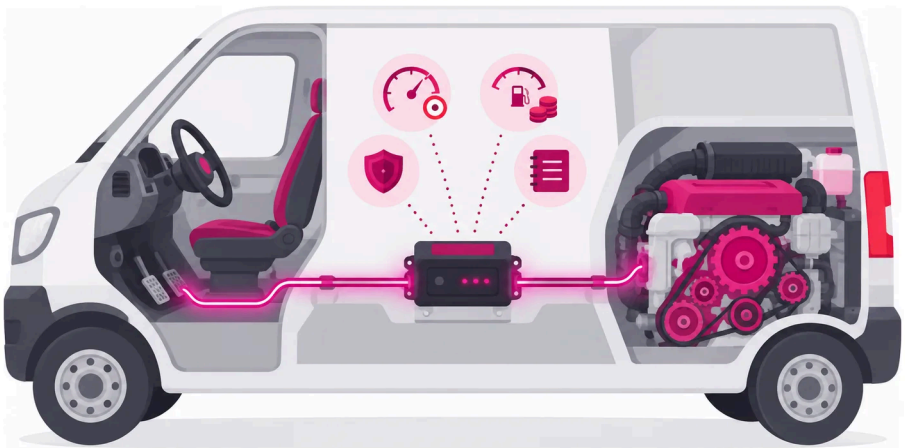
Les trois ensemble : retirez-en un.

© ZENIKA 2026 | All rights reserved

Le boîtier de la flotte

DÉTAIL ↗

EN VRAI une gateway IA · LiteLLM, Kong AI Gateway, Azure API Management



entre la pédale et le moteur : il bride, il compte, il enregistre

Brancher le bon moteur

Un budget par équipe

Des contrôles pour tous

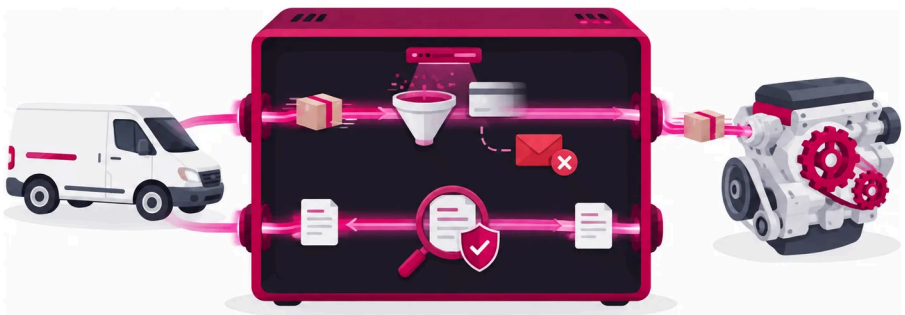
Une boîte noire

© ZENIKA 2026 | All rights reserved

Les contrôles du boîtier

DÉTAIL ↗

EN VRAI les guardrails · Azure AI Content Safety, AWS Bedrock Guardrails, Llama Guard



À l'aller, dans le boîtier

repérer les faux ordres, masquer les données sensibles

Au retour, dans le boîtier

bloquer ce qui ne doit pas partir

Sur les actions, dans le véhicule

autorisations, validation humaine

© ZENIKA 2026 | All rights reserved

Cinq questions à poser à un fournisseur

DÉTAIL ↗

1



Où vont mes données ?

Pays, hébergeur, durée de conservation.

2



Qui peut les voir ?

Servent-elles à entraîner le modèle ?

3



Combien ça coûte ?

À l'usage, au siège, avec quel plafond ?

4



Que peut faire l'agent ?

Lire, écrire, envoyer : avec quel accord ?

5



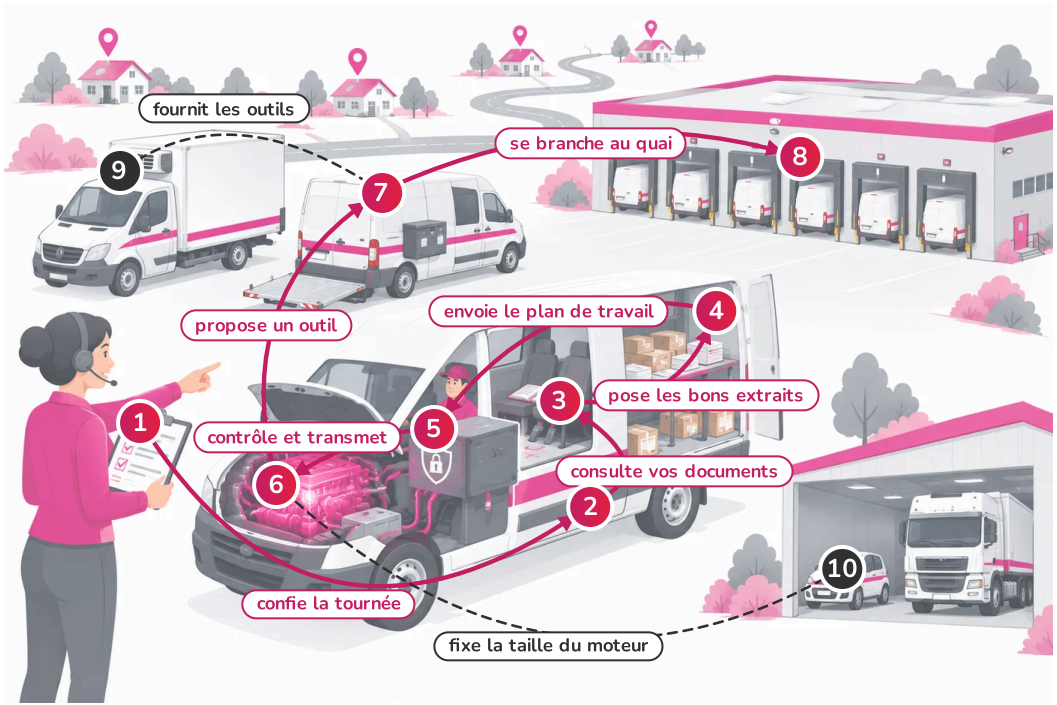
Peut-on changer ?

De moteur, de fournisseur, sans tout refaire ?

© ZENIKA 2026 | All rights reserved

Toute la flotte d’un coup d’œil

DÉTAIL ↗



LE TRAJET D’UNE DEMANDE

1. **Le dispatch et ses bons**
   orchestrateur · SDD
2. **Le véhicule et son chauffeur**
   agent
3. **Le livre ouvert**
   RAG
4. **Le plan de travail**
   context window
5. **Le boîtier et ses contrôles**
   gateway · guardrails
6. **Le moteur**
   LLM
7. **La boîte à outils**
   outils
8. **Le quai standard**
   MCP

CHOISIS AVANT LE DÉPART

9. **L’équipement**
   harness
10. **Citadine ou poids lourd**
    SLM · LLM

© ZENIKA 2026 | All rights reserved

Une demande, de bout en bout

1



Le bon de commande

La spec (SDD), relue par un humain.

2



Le dispatch

L'orchestrateur confie la tâche à un agent.

3



Le véhicule

Le harness prépare le contexte.

4



Le boîtier

La gateway et ses guardrails contrôlent.

5



Le moteur

Le LLM prédit, token par token.

6



La livraison

L'agent agit (outils), on vérifie.

Le moteur prédit, le véhicule agit, le boîtier contrôle.

© ZENIKA 2026 | All rights reserved

Des questions ?

Le moteur prédit, le véhicule agit, le boîtier contrôle.

© ZENIKA 2026 | All rights reserved